

Credit Card Fraud Detection 데이터 분석

1. 데이터셋 특성 파악

31개의 컬럼 중에 28개의 컬럼이 PCA 변환된 변수이다. 개인정보 때문에 PCA 변환된 변수가 많을 것이라고 파악했다. 이외에 Time, Amount, Class 컬럼이 있다. 이 중 Class 변수는 정상거래(0)와 사기거래(1)로 분류되어있는데 약 99.8%가 정상거래일정도로 극단적인 클래스 불균형 데이터셋이다.

2. 데이터 전처리

1) 스케일링

Amount 변수에 Standard Scaling을 적용했다.

2) 데이터셋 분할

전체 데이터를 학습데이터 80%와 테스트데이터 20%로 분리했다.

stratify=y를 적용해 분할된 데이터에도 클래스 비율을 동일하게 유지했다.

3) 데이터 불균형 해결

학습데이터에 SMOTE를 적용해 두 클래스의 비율을 1:1로 맞추었다.(데이터 누수 방지를 위해 학습데이터에만 적용)

SMOTE 적용 이유: 정상거래 데이터가 사기 거래보다 훨씬 많기 때문에 모델이 정상 거래라고만 찍어도 정확도가 매우 높아지기 때문에 제대로 학습이 되지 않을 수 있다. SMOTE를 적용해 두 데이터의 비율을 같게 해주면 사기 거래의 특징을 정상적으로 학습할 수 있다.

3. 모델링

랜덤포레스트 모델을 학습모델로 선정했다.

랜덤포레스트 선정이유

- 별도의 하이퍼파라미터 튜닝 없이도 높은 수준의 분류 정확도와 재현율(Recall)을 확보할 수 있다.
- PCA로 변환된 변수들의 비선형적인 관계를 효과적으로 학습할 수 있다.

4. 분석 결과

1) CLASS 0

precision: 0.99

recall: 1.00

f1-score: 0.92

2) CLASS 1

precision: 0.95

recall: 0.89

f1-score: 0.92

3) PR-AUC

PR-AUC: 0.9537

-> 최종 모델이 목표 $\text{Recall} \geq 0.80$, $\text{F1} \geq 0.88$, $\text{PR-AUC} \geq 0.90$ 을 달성하였다.

랜덤 포레스트 모델이 비선형 패턴을 효과적으로 학습하여 데이터 불균형 환경에서도 올바른 전처리를 한다면 안정적으로 사기거래를 탐지함을 확인할 수 있었다.